

ОСНОВИ СИСТЕМ ШТУЧНОГО ІНТЕЛЕКТУ, НЕЙРОННИХ МЕРЕЖ та ГЛИБОКОГО НАВЧАННЯ

Модуль 2. Навчання з вчителем

Лекція 2.7.

Класифікація. Метод kNN.

Класифікація

Формально:

Маємо множину \mathbb{O} об'єктів $o^{(j)}$, $j = 1, 2, \dots, M$

Кожен об'єкт $o^{(i)}$ має сукупність характеристик - ознак $x_i^{(j)}$, $i = 1, 2, \dots, N$ з множини \mathbb{X} .

Маємо множину \mathbb{C} класів $c^{(k)}$, $k = 2, \dots, K$

Існує невідома залежність (правило) \mathbb{F} , яка на підставі пар $\langle o^{(j)}, c^{(k)} \rangle$ визначає, чи належить об'єкт $o^{(j)}$ до класу $c^{(k)}$.

Завдання: знайти правило $\check{\mathbb{F}}$, максимально наближене до \mathbb{F} . Тобто, знайти вирішальне правило, що дозволяє класифікувати довільний об'єкт o за його ознаками.

Методи Класифікації

- Регресійні методи, логістична регресія
- *Метод k -найближчих сусідів (kNN)*
- Метод опорних векторів (SVM)
- Наївний Байєс (ймовірнісний класифікатор)
- Дерева рішень
-

к-найближчих сусідів (kNN)

KNN (*k-nearest neighbor method*) — метод навчання з вчителем. Метод використовується як для класифікації, так і для регресії. В обох випадках вхідні дані складаються з k найближчих навчальних прикладів у наборі даних. При класифікації результатом k-NN є належність класу. Об'єкт класифікується за допомогою множини голосів його сусідів, при цьому об'єкт належить до класу найбільш поширеного серед його k найближчих сусідів. При регресії результатом є числове значення властивості об'єкту, що є середнім з k найближчих сусідів.

к-найближчих сусідів (kNN)

Спрощено *KNN* працює за простим принципом: об'єкт, швидше за все, буде схожий на своїх «ближчих» сусідів.

Алгоритм розглядає «к» найбільш схожих точок даних (сусідів) і приймає більшість голосів у разі класифікації або середнє значення у разі регресії.



Відстань між точками даних обчислюється за допомогою різних метрик, але найчастіше використовуються Евклідова відстань, відстань Мінковського,

Відстань

«Манхетенська» відстань (метрика Мінковського, L1)

$$\text{dist}(X, Y) = \sum_{i=1}^N |x_i - y_i|$$

Евклідова відстань (метрика L2)

$$\text{dist}(X, Y) = \sqrt{\sum_{i=1}^N (x_i - y_i)^2}$$

Косинусна метрика – кут між векторами

$$\text{dist}(X, Y) = 1 - \frac{\sum_{i=1}^N x_i y_i}{\sum_{i=1}^N (x_i)^2 \sum_{i=1}^N (y_i)^2}$$

к-найближчих сусідів (kNN)

1. **Попередня обробка даних:** Масштабувати функції. Різні масштаби між об'єктами можуть спотворити відстані та привести до неточних прогнозів. Масштабування включають min-max scaling та нормалізацію Z-оцінки.
2. **Вибір показника відстані:** Обирається показник відстані, який відповідає характеру даних.
3. **Визначення значення «k»:** визначення відповідної кількості сусідів є фундаментальним кроком.
4. **Навчання моделі:** KNN «ледачий» учень, тобто модель явно не будується під час «навчання». Зберігається весь набір даних у пам'яті.
5. **Передбачення:** Для нової точки даних обчислюється відстань між нею та **всіма** іншими точками в наборі даних. Далі обирається «k» найближчих і приймається більшість голосів (для класифікації) або середнє значення (для регресії).
6. **Оцінка моделі:** після прогнозів оцінюється якість точність моделі за допомогою відповідних показників.

к-найближчих сусідів (kNN)

Наданий алгоритм **kNN** називається **Brute-Force**, оскільки використовується метод повного перебору для пошуку найближчих сусідів, що робить його простим у реалізації, але вельми повільним при роботі з великим обсягом даних.

Для вирішення цієї проблеми в реалізації *scikit-learn* передбачені більш просунуті методи, що базуються на бінарних деревах, що дозволяє отримати значний приріст у продуктивності.

Дивись:

- Приклад 1
- Приклад 2
- Scikit-learn [KNeighborsRegressor — scikit-learn 1.5.1 documentation](#)

Контрольні запитання

- Надайте загальну постановку задачі класифікації.
- Пояснить сутність методу kNN вирішення задачі класифікації.
- Пояснить процес пошуку параметру k при вирішенні задачі класифікації методом kNN .

Рекомендована ЛІТЕРАТУРА

- **Глибинне навчання:** Навчальний посібник / Уклад.: В.В. Литвин, Р.М. Пелещак, В.А. Висоцька В.А. – Львів: Видавництво Львівської політехніки, 2021. – 264 с.
- Тимощук П. В., Лобур М. В. **Principles of Artificial Neural Networks and Their Applications: Принципи штучних нейронних мереж та їх застосування:** Навчальний посібник. – Львів : Видавництво Львівської політехніки, 2020. – 292 с.
- Morales M. **Grokking Deep Reinforcement Learning.** – Manning, 2020. – 907 с.
- Trask Andrew W. **Grokking Deep Learning.** – Manning, 2019. – 336 с.

Корисні та цікави посилання

- **Машинне навчання**

https://uk.wikipedia.org/wiki/машинне_навчання

- **Львівська політехніка**

<http://www.mmf.lnu.edu.ua/ar/1739>

<http://www.mmf.lnu.edu.ua/ar/1743>

Приклади дивись

Lec_02_07_Exmpl_1.md

Lec_02_07_Exmpl_2.md

The END

Модуль 2. Лекція 2.7.